

**МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
Ордена Трудового Красного Знамени
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский технический университет связи и информатики»**

Кафедра «Математическая кибернетика и информационные технологии»

Лабораторная работа №10

по дисциплине «Математические основы баз данных»

по теме:

«Обращение к Базе данных на естественном языке.»

Выполнил: Студент группы
БПИ2403

Сон Владимир Сергеевич

Проверил:

Старший преподаватель
Фатхулин Тимур Джаилиевич

Москва
2025

Цель работы

Изучить механизмы работы с созданием модели, посредством которой реализуется обращение к базе данных на естественном языке.

Основные теоретические сведения

- NLP (Natural Language Processing) - обработка естественного языка;
- TAPAS - нейросетевая модель Google AI для ответов на вопросы по табличным данным;
- Токенизация - разбиение текста на отдельные элементы (токены);
- TensorFlow/Transformers - библиотеки для машинного обучения.

Задачи

1. Импортировать таблицу из базы данных;
2. Подключить базу данных к среде Google Collab;
3. Создать модель и функцию, обучение которых приводит к нужным результатам;
4. Задать вопросы базе данных.

Ход работы

1) Импортируем таблицу из базы данных

```
> sudo mariadb -D TradingArea -e "SELECT ClientID, REPLACE(CompanyName, ',', ';') as  
  CompanyName, REPLACE(Address, ',', ';') as Address, Phone, BankDetails, REPLACE(Con  
  tactPerson, ',', ';') as ContactPerson FROM Client" | sed 's/\t/,/g' > ~/TradingArea  
Data/client.csv  
> sudo mariadb -D TradingArea -e "SELECT * FROM Store" | sed 's/\t/,/g' > ~/TradingA  
reaData/store.csv  
> sudo mariadb -D TradingArea -e "SELECT LeaseID, ContractID, StoreID, REPLACE(Lease  
  Period, ',', ';') as LeasePeriod FROM Lease" | sed 's/\t/,/g' > ~/TradingAreaData/Le  
ase.csv
```

2) Подключаем базу данных к среде Google Collab. Создаём модель и функцию, обучение которых приводит к нужным результатам

```

from transformers import AutoModelForTableQuestionAnswering, AutoTokenizer, pipeline
import pandas as pd
from google.colab import drive

drive.mount('/content/drive')

client_data = pd.read_csv('/content/drive/MyDrive/TradingAreaData/client.csv')
print(client_data.head())

store_data = pd.read_csv('/content/drive/MyDrive/TradingAreaData/store.csv')
print(store_data.head())

lease_data = pd.read_csv('/content/drive/MyDrive/TradingAreaData/lease.csv')
print(lease_data.head())

client_data = client_data.astype(str)
store_data = store_data.astype(str)
lease_data = lease_data.astype(str)

model_name = 'google/tapas-base-finetuned-wtq'
tapas_model = AutoModelForTableQuestionAnswering.from_pretrained(model_name)
tapas_tokenizer = AutoTokenizer.from_pretrained(model_name)

nlp = pipeline('table-question-answering',
               model=tapas_model,
               tokenizer=tapas_tokenizer)

def ask_question(query, data):
    result = nlp({'table': data, 'query': query})
    answer = result['cells']
    return answer

ask_question(
    "What is the maximum DailyRentCost?",
    store_data
)

```

Импортированы нужные библиотеки для работы с моделью. Подключён Google Диск для экспорта БД и конвертированы данные из CSV. Загружена модель TAPAS и создана функция для задавания вопросов.

3) Задаём вопросы базе данных

```

*** Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
ClientID      CompanyName      Address \
0      1      000 "Силсонг"      г. Москва; ул. Мтуси; д. 1
1      2      ЗАО "KDECALL"      г. Москва; ул. Мтуси; д. 34а
2      3      000 "Гномики"      г. Москва; ул. Мтуси; д. 89
3      4      ЗАО "Sonderkraftfahrzeug"      г. Байконур; ул. Янгеля; д. 6
4      6      ОАО "МамДайДеняг"      г. Москва; ул. Мтуси; д. 25

Phone      BankDetails      ContactPerson
0 8 (999) 111-22-33 40702810580000001111 Дзикович Максим Вячеславович
1 8 (999) 444-55-66 40704577890000001111 Лучшев Вадим Алексеевич
2 8 (999) 777-88-99 40708983440000001111 Голубенко Максим Алексеевич
3 8 (916) 675-75-75 40700542010000001111 Сон Владимир Сергеевич
4 8 (999) 535-67-89 40702810222222222222 Сон Андрей Сергеевич

StoreID Floor Area HasAirConditioning DailyRentCost ShoppingCenterID
0 8 1 50.00 1 2500.0 4
1 9 1 120.50 1 5500.0 4
2 10 2 75.25 0 3200.0 4
3 11 1 200.00 1 9000.0 5
4 12 3 45.75 1 1800.0 5

LeaseID ContractID StoreID LeasePeriod
0 1 1 8 12 месяцев
1 2 1 9 6 месяцев
2 3 1 10 6 месяцев
3 4 2 11 18 месяцев
4 5 2 12 6 месяцев
Device set to use cpu
/usr/local/lib/python3.12/dist-packages/transformers/models/tapas/tokenization_tapas.py:2700: FutureWarning: Series.__getitem__ t
text = normalize_for_match(row[col_index].text)
/usr/local/lib/python3.12/dist-packages/transformers/models/tapas/tokenization_tapas.py:1494: FutureWarning: Series.__getitem__ t
cell = row[col_index]
['9000.0']

```

Вывод

В ходе работы была изучена и успешно протестирована система для интерактивного взаимодействия БД с использованием технологий обработки естественного языка (NLP).